

## IIC2440 – Procesamiento de Datos Masivos

### I1

**Instrucciones.** La interrogación tiene una duración de 100 minutos.

Resuelve cada problema en una hoja separada. Las preguntas cortas generalmente tienen una mayor probabilidad de estar correctas. Todas las preguntas tienen 2 puntos; la nota final se calcula como la suma de los puntos obtenidos de cada pregunta, más un punto base.

Las preguntas se hacen en voz alta; solo en el intervalo de tiempo **de 15:50 a 16:10**.

**Problema 1** Te encuentras con un amigo que no tomó este curso, pero que está trabajando en una aplicación y un warehouse. En la conversa, te cuenta:

Tengo un montón de datos y los actualizo solo una vez por semana, entonces armé una base de datos columnar. Pero estoy súper defraudado de esta tecnología, no se siente tan rápida. Mi problema es el siguiente. Tengo una tabla **T** que guarda cada venta que hice, almacenando el id de la venta, tipo de producto, el mes, el año, el costo de ese producto por unidad, la cantidad de unidades y el precio de venta por unidad.

Entonces, arme un sistema al cual le paso un tipo de producto `<tipo_producto>` y un año `<ano>`, y ejecuta:

```
SELECT T.tipo_prod, T.ano, ((T.venta_uni - T.costos_uni) * T.cantidad) AS margen
FROM T
WHERE T.ano = <ano> AND T.tipo_prod = <tipo_producto>
```

y después, con esta información, uso Python para armar una interfaz visual que me compute los indicadores que quiero.

- [0,4 pts] Explicale a tu amigo por qué esa consulta corre mal en bases de datos columnares.
- [0,6 pts] Si tu amigo insiste en usar bases de datos columnares, sugierele como puede primero pre-procesar sus datos usando SQL en otra tabla  $T'$ , en un computo caro pero que ocurre una vez a la semana, y luego levantar una consulta SQL que si funcione bien para bases de datos columnares, y que entregue la misma información.

Ahora supón que para llegar a esa tabla, tu amigo ejecuta una instrucción que levanta datos desde una base de datos relacional usual (transaccional, no columnar). Esta consulta corre todos los meses `<mes>`, asumiendo que el año actual es `<ano>`, y el resultado es insertado en la tabla **T**:

```
SELECT P.tipo_prod, P.costos_uni, V.ano, V.cantidad, V.venta_uni, V.id_venta
FROM Productos P, Ventas V
WHERE P.id_producto = V.id_producto AND V.mes = <mes> AND V.ano = <ano>
```

Es decir, a cada información de la tabla de ventas le adjunta el tipo de producto y el costo, que están en una tabla de Productos. El join es por id de producto, `id_producto` es llave de **Productos** y `id_venta` es llave de **Ventas**.


Tu amigo dice que para acelerar esta consulta puso un índice en `id_producto` en la tabla de **Ventas**. Pero ahora tú vas a explicarle que ese índice no sirve para esta consulta, y recomendarle otras cosas. Para esta consulta puedes asumir que tu amigo maneja datos desde 1990.

- [0,5 pts] Explica qué tipo de join probablemente está haciendo esta base de datos y por qué no es necesario ese índice.
- [0,5 pts] Recomiéndale un índice que si podría servirle, y explícale por qué.

**Problema 2** Estás en una entrevista técnica para el cargo de Ingeniero de Datos. Para evaluar tu capacidad de diseñar flujos de información y entender el funcionamiento de herramientas, el entrevistador te plantea las siguientes preguntas breves:

- [0,6 pts] Cómo construirías un flujo de datos (*pipeline*) para disponibilizar los datos que tenemos en bases de datos transaccionales en producción y poder analizarlos. Menciona las herramientas/tecnologías que usarías.
- [0,7 pts] ¿En qué se basa la capacidad de cómputo de BigQuery? ¿Por qué debemos evitar el uso de `<SELECT *>` en nuestras consultas de BigQuery?
- [0,7 pts] BigQuery implementa distintos tipos de JOINS internos. Explica el funcionamiento de uno y cuándo es que el optimizador *elige* usarlo.

**Problema 3** Tras tu entrevista, te han aceptado y ahora trabajas en una aplicación de streaming de música. Como primera tarea, te han pedido que hagas algunos análisis usando el modelo ya cargado en BigQuery, el cual tiene el siguiente esquema:



**A) [1 pto]** Escribe pseudocódigo de cómo se deben resolver las siguientes consultas:

- Obtener las 3 canciones con mayor tiempo total de reproducción para cada país. El resultado debe mostrar el país, el nombre de la canción y su posición en el ranking.
- Con una ventana de 5 días, calcula la media móvil de reproducciones diarias para `artista='Daft Punk'`.

**B) [1 pto]** El equipo de negocio solicita ahora el total de "saltos" (`fue_saltada=TRUE`) que realizan los usuarios por cada **trimestre**<sup>1</sup>, filtrando únicamente por reproducciones realizadas desde un **teléfono móvil**. Considerando que el modelo actual no posee el campo "dispositivo" ni "trimestre":

- Propón las modificaciones necesarias al esquema y justifica tu decisión. ¿Qué complejidades implica el cambio?
- Entrega el pseudocódigo final de la consulta con los cambios propuestos.

<sup>1</sup>Primer trimestre (enero-marzo), segundo (abril-junio), tercero (julio-septiembre), cuarto (octubre-diciembre); para cada año.