

IIC 2440 – Procesamiento de Datos Masivos

Tarea 2

Instrucciones. Esta tarea debe resolverse en grupos de a dos personas.

El formato de entrega consta de los siguientes archivos:

- Un archivo comprimido con todo el código usado para el trabajo (pero no los datos; si suben los datos habrá descuento).
- Un informe en PDF donde se reporten los resultados, las visualizaciones y las decisiones de diseño, con sus justificaciones.


El uso de herramientas de IA generativa está permitido y se recomienda su uso. Sin embargo, esta tarea promueve un uso responsable y ético; se asume que los alumnos son responsables por todo el material generado y comprenden y son familiares con el trabajo realizado. El equipo docente se reserva el derecho de bajar la nota a aquellos alumnos o grupos que no lo demuestren.

Fechas. La fecha de entrega de la tarea es el miércoles 1 de julio, a las 20:00 hrs.

Introducción. En esta tarea van a construir un sistema de **preguntas y respuestas** (estilo RAG) sobre una colección de **intervenciones en sesiones del poder legislativo chileno**. Partirán de una recuperación densa simple, agregarán recuperación sobre grafo (**GraphRAG**) usando **MillenniumDB**, y finalmente construirán un recuperador propio basado en vectores *sparse* que deberán combinar con el denso. El foco no es “que funcione” (con asistentes de IA eso es relativamente rápido), sino que **comparen estrategias de recuperación, midan su calidad y justifiquen** cuál sirve mejor para cada tipo de pregunta.

Nos interesa saber el porqué de las decisiones que tomen en el desarrollo, expliquen por qué creen que fallan las respuestas con algunas estrategias. No hay soluciones únicas para esta tarea, les invitamos a ser creativos.

Datos. Recibirán un archivo CSV y otro .qm con las intervenciones y su metadata, este último es el formato de carga que acepta MillenniumDB. Deberán **levantar una instancia local de MillenniumDB** y cargar los datos en ella:



Cada intervención viene acompañada de su **vector denso ya calculado** por el equipo docente con el modelo **multilingual-e5-base** (dimensión 768). **No deben recalcular los vectores densos.** Una advertencia importante: **e5** es un modelo asimétrico que espera el prefijo **passage:** en los documentos y **query:** en las consultas, y trabaja con similitud coseno sobre vectores normalizados.

El grafo tiene información adicional que puede que no necesiten.

La imagen adjunta nos dice lo siguiente:

- Los nombres dentro de los cuadros son los **LABELS** de aquellos nodes
- Las relaciones entre los tipos de nodes son dirigidas, los **LABELS** de estas relaciones son los nombres que se ven en el diagrama
- Por ejemplo: los nodes **Persona** tienen una relación de tipo **ServedAs** que apunta a los nodes **Position**.

Estructura del trabajo. El trabajo consta de cuatro partes. En la Parte 1 implementan un RAG denso simple sobre MillenniumDB. En la Parte 2 lo extienden con consultas sobre el grafo (GraphRAG). En la Parte 3 construyen un recuperador *sparse* propio y lo combinan con el denso mediante fusión y un *rerank*. En la Parte 4 comparan todas las estrategias sobre un mismo conjunto de preguntas, con evaluación manual y visualizaciones.

Parte 0: Carga de datos a MillenniumDB (10 %)

0.1 Levantar MDB. Seguir las instrucciones de la Wiki para poder levantar MillenniumDB

0.2 Carga. Carguen los datos en su instancia local a partir del `.qm` generado, e indexen los vectores densos para búsqueda por similitud usando HNSW.

0.3 Hello World! Realice consultas simples para validar que los datos se hayan cargado correctamente (COUNT de nodos, relaciones o un MATCH simple). Para poder usar MillenniumDB desde Python deben de usar el driver descargándolo desde PyPi

Parte 1: RAG denso (10 %)

1.1 Recuperación densa. Implementen el flujo RAG clásico: la pregunta se vectoriza, se recuperan las **top- k** intervenciones por similitud de vectores **usando la búsqueda por similitud de MillenniumDB**, y se entregan como contexto a un LLM que redacta la respuesta citando las intervenciones usadas.

1.2 Generación. La generación de respuestas debe usar el modelo `gpt-4o-mini` con la llave que les entregaremos. Fijen y reporten k y el *prompt* usado. **Este mismo modelo y *prompt* se mantendrán fijos en todas las partes:** lo único que cambia entre estrategias es el retriever.

1.3 Pruebas. Prueba tu entorno RAG con algunas preguntas. ¿Hay algo que te interese saber sobre la labor legislativa en Chile?

Parte 2: GraphRAG (25 %)

MillenniumDB permite combinar, en una misma consulta, **patrones sobre el grafo y similitud de vectores**. Aprovechen esto para responder preguntas que la recuperación densa pura no resuelve bien. Noten que las rutas en este grafo son **cortas**: el valor no está en travesías profundas, sino en *filtrar la búsqueda semántica por atributos tipados y agregar*.

2.1 Patrones de consulta. Implementen al menos los siguientes patrones (con la sintaxis de MillenniumDB):

- **Recuperación con restricción tipada:** intervenciones similares a la pregunta usual en RAG, pero filtradas por partido, cámara o período. Ejemplo: “¿qué opina el partido X sobre el tema Y?”
- **Agregación / contraste:** recuperar semánticamente sobre un tema y agrupar por partido o por cámara para contrastar posturas.
- **Una consulta que use un atributo numérico/temporal:** por ejemplo, contrastar cómo hablan de un tema las personas según su **cohorte etaria** (a partir de la fecha de nacimiento) o según la **fecha** de la intervención.

Estos patrones pueden combinarse en MillenniumDB con el acceso a vectores. Entonces, la recuperación busca todos los textos que se recuperan con el patrón, ordenados por similitud de coseno usando el índice HNSW.

2.2 Comparación. Muestren al menos un caso donde GraphRAG entregue resultados claramente mejores que el RAG denso de la Parte 1, y expliquen por qué.

Parte 3: Recuperación híbrida (sparse + denso) (25 %)

MillenniumDB solo maneja vectores densos. En esta parte cubrirán el flanco que los densos hacen mal (términos exactos, jerga, apellidos, números de boletín) construyendo un recuperador *sparse* propio y combinándolo con el denso.

3.1 Vectores sparse. Generen una representación *sparse* de las intervenciones con la estrategia que estimen mejor (por ejemplo, TF-IDF, BM25, pero hay muchas estrategias). **Deben argumentar en el informe por qué eligieron esa estrategia.**

3.2 Almacenamiento. Deben decidir **cómo y dónde** alojan estos vectores y poder consumirlos. Las llaves de su *store* sparse deben corresponder a los **mismos identificadores** de los nodos/documentos que usa MillenniumDB, para poder cruzar resultados y recuperar el contexto del grafo.

3.3 RAG con recuperación esparsa. Implementen un pipeline de RAG en donde los documentos a entregar son los que minimizan la distancia con los vectores sparse (notar que la distancia depende de la estrategia de la recuperación)

3.4 Fusión + Rerank. Implementen un pipeline de RAG en donde los documentos a entregar vienen de un ranking elaborado sobre lo que entrega la recuperación densa y la recuperación sparse. Existen muchas estrategias para combinar ambos ranking, por ejemplo, *Reciprocal Rank Fusion* o *Maximal Marginal Relevance*. **No se permite usar el LLM para la reordenación** (no usar LLM as a judge).

Parte 4: Evaluación y comparación (30 %)

4.1 Preguntas. Responderán un total de **9 preguntas**: 7 entregadas por el equipo docente y **2 diseñadas por ustedes**, que deben estar pensadas para discriminar entre estrategias (es decir, donde esperen que una estrategia gane sobre otra).

1. ¿Qué argumentos a favor y en contra surgieron en el debate sobre la reducción de la jornada laboral a 40 horas semanales, considerando aspectos como la conciliación entre la vida familiar y el trabajo, la productividad y el efecto sobre las pymes?
2. En torno a la despenalización del aborto, la interrupción voluntaria del embarazo, los derechos reproductivos y la objeción de conciencia, ¿cómo se diferencia la manera en que se han pronunciado los legisladores hombres frente a las legisladoras mujeres?
3. Sobre el impacto ambiental de la minería, el royalty minero, la escasez hídrica y el desarrollo de las comunidades del norte, ¿qué diferencias se observan entre lo que plantean quienes representan distritos con comunas mineras y quienes representan zonas sin actividad minera?
4. En materia de migración irregular, expulsión de extranjeros, crisis migratoria en la frontera norte y seguridad fronteriza, ¿qué posturas defienden los distintos partidos políticos y en qué se contraponen entre sí?
5. Identifica las intervenciones en que se mencionan de forma explícita el “CAE” (Crédito con Aval del Estado), la “condonación” de la deuda educativa y el nuevo “FES” (Financiamiento para la Educación Superior); ¿en qué contextos aparecen exactamente estos términos?
6. ¿Cómo se ha discutido el uso de la fuerza policial y la legítima defensa de Carabineros, en particular en aquellas intervenciones que se refieren específicamente a la Ley Naín-Retamal?
7. ¿Qué proyectos de ley sobre la muerte digna, la eutanasia y los cuidados paliativos terminaron archivados, y qué se argumentó en las intervenciones asociadas a esos proyectos?

4.2 Configuraciones a comparar. Para *cada* pregunta, ejecuten y comparen las siguientes cinco configuraciones de recuperación, manteniendo fija la generación:

1. Denso solo (Parte 1).
2. GraphRAG (Parte 2).
3. Sparse solo (Parte 3).
4. Híbrido por fusión RRF y/o rerank (denso + sparse).

4.3 Evaluación manual. Para cada pregunta y cada configuración, recuperen el top- k y **asignen a mano una nota de 1 a 7** a cada resultado recuperado, según cuán pertinente sea para responder la pregunta. A partir de esas notas, calculen al menos una **métrica agregada comparable entre configuraciones**. Recomendamos un k tal que permita que la evaluación manual sea abordable.

4.4 Visualización. Presenten al menos una **visualización** que muestre la métrica anterior comparando las cinco configuraciones.

4.5 Análisis. Escriban un análisis donde discutan: en qué tipo de preguntas gana cada estrategia y por qué; cuánto aporta la fusión y el rerank; y si una mejor recuperación se tradujo en una mejor respuesta final del LLM. Justifiquen, además, las decisiones de diseño tomadas a lo largo de la tarea (prompts, granularidad, estrategia sparse, fusión, rerank, etc.).

Restricciones y descuentos

Restricciones.

- La recuperación densa debe vivir en MillenniumDB; el recuperador sparse debe ser propio (no usar otro motor de vectores para el denso).
- **No** se permite usar el LLM como juez de la evaluación (la evaluación es manual, nota 1–7) ni como reordenador en el *rerank*.
- La generación de respuestas se mantiene fija (`gpt-4o-mini`, mismo *prompt*) en todas las configuraciones.

Descuentos.

- Uso de LLM as a judge
- Subir datos en entrega
- No usar modelo de embeddings densos o modelo de GPT especificados en el enunciado
- Mal uso del token de OpenAI

Bonus.

- Dado que MillenniumDB se encuentra en desarrollo continuo, podrías llegar a encontrar algún bug. Si logras replicarlo y lo compartes en las issues del curso, recibirás +0.4 en la nota de la tarea.